

Entendimiento de datos

Proyecto RaSA — Perfilamiento, análisis de calidad y conclusiones de viabilidad

Base de datos fuente: **RaSaTransaccional** · Tecnología: PySpark sobre JupyterLab
Fuentes analizadas: Áreas de servicio, Tipos de beneficio, Planes-beneficio (tabla central) y Condiciones de pago (referencia).

Resumen ejecutivo

Se analizaron cuatro fuentes suministradas por RaSA con el fin de determinar si es posible desarrollar los análisis de negocio solicitados. El diagnóstico confirma que las fuentes contienen la información necesaria para relacionar planes, beneficios, áreas de servicio y condiciones de pago, pero también revela problemas de completitud, unicidad, validez y consistencia que deben tratarse antes de construir el modelo dimensional. La conclusión es que el proyecto es **viable con una etapa previa de depuración**, dejando documentados los supuestos y las decisiones de limpieza.

Indicadores clave del diagnóstico

Fuente	Registros	Columnas	Duplicados completos	Hallazgo principal
Áreas de servicio	188.815	9	43.573 (23,1%)	Fechas y áreas fuera de rango; llave con nulos
Tipos de beneficio	849	9	271 (31,9%)	Banderas en varios idiomas; 178 ≠ 170 esperados
Planes-beneficio	36.036	11	8.493 (23,6%)	Llaves foráneas nulas y huérfanas; grano indefinido
Condiciones de pago	31	3	7 (22,6%)	Identificador repetido; 14 copagos (esperado 15)

1. Objetivo y alcance

El objetivo de la etapa de entendimiento de datos es explorar las fuentes provistas por RaSA, inspeccionar su nivel de calidad y evaluar la viabilidad de implementar los análisis solicitados. El trabajo se organiza en tres momentos que alimentan la decisión final:

- **Perfilamiento (Entregable 1):** exploración de estructura, volumen y contenido de cada fuente, con registro de observaciones descriptivas que sirven de insumo para el análisis formal.
- **Calidad de datos (Entregable 2):** evaluación de las cuatro dimensiones vistas en el curso — completitud, unicidad, validez y consistencia — contra las reglas de negocio comunicadas por RaSA.
- **Conclusiones (Entregable 3):** validación de la viabilidad de los análisis, identificación de las columnas de integración entre fuentes y consolidación de supuestos y dudas para el negocio.

Cada fila de las fuentes tiene un significado de negocio definido, resumido a continuación.

Fuente	Tabla en RaSaTransaccional	Significado de una fila
Áreas de servicio	FuenteAreasDeServicio_Copia_E	Un área de servicio definida sobre un condado, con población, área y densidad.
Tipos de beneficio	FuenteTiposBeneficio_Copia_E	Un tipo de beneficio y sus atributos (si es EHB, si tiene límite cuantitativo, exclusiones).
Planes-beneficio	FuentePlanesBeneficio_Copia_E	Un beneficio ofrecido por un plan en un área, con copago, coseguro y condiciones. Tabla central.
Condiciones de pago	FuenteCondicionesDePago_Copia_E	Una condición de pago de referencia (copago o coseguro).

RaSA comunicó además las siguientes cifras y reglas esperadas, usadas como referencia de contraste: 5.409 áreas de servicio que cubren todos los condados; 170 tipos de beneficio; 301 planes en 2017 y 422 en 2018; valores máximos de copago y coseguro para 2018 de 3.300 y 100; 15 condiciones de copago y 5 de coseguro; información de los años 2017 a 2019; y beneficios con límite cuantitativo que deben tener una cantidad límite distinta de cero.

2. Perfilamiento de datos

El perfilamiento se ejecutó cargando cada fuente vía Java Database Connectivity y aplicando funciones reutilizables de resumen (volumen y esquema), conteo de nulos, cardinalidad y frecuencias. Sus resultados son **exploratorios** y se confirman formalmente en el análisis de calidad. En particular, los conteos por año de esta fase se calcularon con una extracción sencilla del año y por tanto son orientativos hasta estandarizar el formato de fecha.

2.1 Áreas de servicio

- La tabla tiene **188.815 filas** pero solo **5.409** valores distintos de `IdAreaDeServicio_T` (justo la cifra del negocio): cada área se repite alrededor de 35 veces, por lo que el identificador no es único por fila.
- La llave `IdAreaDeServicio_T` presenta 3,3% de nulos e `IdGeografia_T` 3,4%; `Area` y `Densidad`, 1,3%. Que la llave del área venga nula impide integrar esas filas.
- Validez: `Area` alcanza un mínimo negativo (-24.707), imposible; `PoblacionAct` llega a cerca de 47.000 millones, claramente atípico; la `Fecha` toma años 2017, 2018 y un inválido 1800, y no aparece 2019.
- Cobertura observada: alrededor de 35 estados y cerca de 4.250 condados, por debajo de la cobertura nacional esperada.

2.2 Tipos de beneficio

- 849 filas con solo **178** valores distintos de `IdTipoBeneficio_T`: 8 más que los 170 esperados y repetición del identificador.
- Completitud aparente del 100% en nulos, pero `UnidadDelLimite` tiene 559 celdas vacías (cadenas en blanco), que el perfilamiento por nulos no detecta y sí captura el análisis de completitud.
- Las banderas booleanas mezclan codificaciones e idiomas: por ejemplo `TieneLimiteCuantitativo` toma No, Yes, Nein (alemán) y Si (español); `EsEHB` combina Yes/No con True.

2.3 Planes-beneficio (tabla central)

- 36.036 filas y 393 valores distintos de `IdPlan_T`. La repetición del plan es esperable, pues un plan cubre varios beneficios y áreas; el problema son los 8.493 duplicados completos.
- Llaves foráneas incompletas: `IdTipoBeneficio_T` 5,8% nulo e `IdAreaDeServicio_T` 5,7% nulo. `cantidadLimite` está 84,8% nula, lo cual es coherente con que solo aplica a beneficios con límite cuantitativo.
- `valorCopago` alcanza 3.500 (200 por encima del tope de 3.300 del negocio); `valorCoseguro` máximo 100, que sí coincide.
- El conteo de planes por año no es confiable en esta fase porque la `Fecha` aparece en formatos mezclados.

2.4 Condiciones de pago

- 31 filas, sin nulos, pero con identificador y descripción repetidos, por lo que la fila no representa una entidad única.
- El campo `Tipo` contiene, además de copago y coseguro, valores no estandarizados que se validan formalmente en la dimensión de validez.

3. Análisis de calidad de datos

Sobre las mismas fuentes se evaluaron las cuatro dimensiones de calidad. A diferencia del perfilamiento, aquí el año se extrae con un parser tolerante a varios formatos y la completitud considera tanto valores nulos como cadenas vacías, lo que corrige la subestimación observada en la fase exploratoria.

3.1 Completitud

La completitud mide si los campos requeridos contienen información suficiente. CondicionesDePago no presenta faltantes. Los casos relevantes son:

Fuente	Campo	Faltantes	%	Lectura
Planes-beneficio	cantidadLimite	30.571	84,83	Esperable: solo aplica a beneficios con límite.
Tipos de beneficio	UnidadDeLimite	559	65,84	Vacíos; interpretar junto a TieneLimiteCuantitativo.
Áreas de servicio	IdGeografia_T	6.378	3,38	Campo geográfico incompleto.
Áreas de servicio	IdAreaDeServicio_T	6.288	3,33	Crítico: es llave de integración con planes.
Planes-beneficio	IdTipoBeneficio_T	2.086	5,79	Llave foránea incompleta.
Planes-beneficio	IdAreaDeServicio_T	2.041	5,66	Llave foránea incompleta.

La completitud es **parcialmente adecuada**: los faltantes en llaves de integración y en atributos requeridos para validar límites cuantitativos deben resolverse con reglas explícitas antes del modelado.

3.2 Unicidad

Ninguna de las llaves simples evaluadas identifica de forma única cada fila: todas presentan duplicados completos y repetición de identificadores.

Fuente	Total	Únicos	Duplic. completos	%	Distintos de la llave
Áreas de servicio	188.815	145.242	43.573	23,08	5.410 (IdAreaDeServicio_T)
Tipos de beneficio	849	578	271	31,92	178 (IdTipoBeneficio_T)
Planes-beneficio	36.036	27.543	8.493	23,57	393 (IdPlan_T)
Condiciones de pago	31	24	7	22,58	23 (IdCondicionesDePago_T)

En PlanesBeneficio se probó una llave compuesta (plan, tipo de beneficio, área, proveedor y fecha). No resuelve la unicidad: deja **48,16%** de duplicados y varios registros repetidos tienen IdTipoBeneficio_T nulo. Es decir, el problema está tanto en la definición de la llave como en la calidad de los campos que deberían conformarla. Se recomienda eliminar duplicados completos y tratar los nulos en campos clave antes de definir el grano real de la tabla.

3.3 Validez

La validez evalúa si los valores respetan formatos, dominios y rangos esperados. Los principales incumplimientos son:

Fuente	Campo	Regla	Registros inválidos
Áreas de servicio	Fecha	Año entre 2017 y 2019	6.282
Áreas de servicio	Area	El área debe ser mayor que cero	6.177
Planes-beneficio	Fecha	Año entre 2017 y 2019	2.052
Tipos de beneficio	TieneLimiteCuantitativo	Valor booleano reconocible	24
Planes-beneficio	valorCopago	En 2018 no debe superar 3.300	8
Condiciones de pago	Tipo	Debe ser copago o coseguro	5
Tipos de beneficio	ExcluidoDelDesembolsoMaximoDentroDeLaRed	Valor booleano reconocible	2

Nota metodológica

El conteo de copagos que superan el tope de 2018 depende de una lectura correcta de la fecha. Se recomienda aplicar en esta regla el mismo parser tolerante a formatos usado en el resto del análisis, para no subestimar los registros almacenados en formatos no estándar. De forma análoga, las banderas en distintos idiomas deben homologarse a un único formato aunque hoy algunas se acepten como válidas.

3.4 Consistencia

La consistencia contrasta los datos con las reglas de negocio y verifica la integridad referencial desde la tabla central hacia las de referencia.

Validación	Esperado	Encontrado	Estado
Beneficios con límite y cantidadLimite válida	0 inconsistentes	14.471	No cumple
Integridad: IdAreaDeServicio_T en planes	0 huérfanos	4.979	No cumple
Integridad: IdTipoBeneficio_T en planes	0 huérfanos	2.023	No cumple
Tipos de beneficio distintos	170	178	No cumple
Condiciones de copago	15	14	No cumple
Planes distintos 2017	301	203	No cumple
Planes distintos 2018	422	287	No cumple
Integridad: condición de copago / coseguro	0 huérfanos	0	Cumple

El hallazgo más crítico son los 14.471 registros de planes asociados a beneficios con límite cuantitativo cuya cantidadLimite es nula, cero o inválida. Los déficits de planes por año (203 frente a 301, y 287 frente a 422) se explican en gran parte por la combinación de **fechas en formatos corruptos**, **llaves foráneas nulas** y **referencias huérfanas**, más que por ausencia real de planes. La consistencia es, por tanto, baja para avanzar directamente al modelado.

4. Conclusiones del entendimiento de datos

4.1 Viabilidad de los análisis solicitados

Sí es posible desarrollar los análisis de negocio solicitados, porque las fuentes contienen la información necesaria para relacionar planes, beneficios, áreas de servicio y condiciones de pago. No obstante, los resultados deben interpretarse considerando las limitaciones identificadas y, preferiblemente, después de una etapa de limpieza y estandarización. Los problemas que más impactan el análisis son la duplicación en todas las fuentes, los nulos en llaves de integración, las diferencias frente a los conteos esperados, las fallas de integridad referencial y los dominios y formatos heterogéneos.

4.2 Integración de las fuentes

La fuente central es **FuentePlanesBeneficio_Copia_E**, que relaciona planes, beneficios, áreas y condiciones de pago. Las columnas de integración observadas — con los nombres reales de las tablas — y su tasa de registros huérfanos son:

Desde (Planes)	Hacia (referencia)	Columna destino	Huérfanos
IdTipoBeneficio_T	TiposBeneficio	IdTipoBeneficio_T	2.023
IdAreaDeServicio_T	AreasDeServicio	IdAreaDeServicio_T	4.979
IdCondicionDePagoCopago_T	CondicionesDePago	IdCondicionesDePago_T (rol Copago)	0
IdCondicionDePagoCoseguro_T	CondicionesDePago	IdCondicionesDePago_T (rol Coseguro)	0

La estructura corresponde conceptualmente a un **esquema tipo estrella**: PlanesBeneficio como tabla de hechos y AreasDeServicio, TiposBeneficio y CondicionesDePago como dimensiones de referencia. El principal bloqueante para materializar el modelo es que **el grano de la tabla de hechos aún está indefinido**: IdPlan_T no representa por sí solo el nivel de detalle, y la llave compuesta probada sigue dejando duplicados y depende de campos que hoy tienen nulos.

4.3 Ajustes recomendados antes del análisis

1. Eliminar registros duplicados completos en las cuatro fuentes.
2. Definir y validar la llave primaria y el grano exacto de cada fuente, en especial de PlanesBeneficio.
3. Corregir o imputar los valores nulos presentes en las llaves de integración.
4. Estandarizar los formatos de fecha con un parser único y tolerante a formatos.
5. Normalizar los dominios categóricos y homologar las banderas booleanas a un único formato.
6. Revisar los registros que incumplen integridad referencial (huérfanos).
7. Confirmar con el negocio los conteos esperados de áreas, tipos de beneficio y planes por año.

4.4 Supuestos realizados

- IdAreaDeServicio_T identifica un área de servicio; IdTipoBeneficio_T, un tipo de beneficio; IdCondicionesDePago_T, una condición de pago.
- IdPlan_T identifica un plan, pero no representa la granularidad completa de PlanesBeneficio, que se asume como el nivel de detalle más bajo del modelo.
- Los registros duplicados corresponden a problemas de calidad y no a eventos legítimos del negocio.
- Los nulos en las llaves de integración representan información faltante y no categorías válidas.

4.5 Dudas e información requerida al negocio

- ¿Cuál es la llave primaria oficial y la granularidad exacta de cada fuente, en particular de PlanesBeneficio?
- ¿Por qué el número observado de tipos de beneficio (178) difiere del esperado (170)?
- ¿Cuál es la causa de los duplicados en las cuatro fuentes y cómo deben tratarse las llaves foráneas nulas?
- ¿Los registros huérfanos son errores de captura o información faltante en las tablas de referencia?
- ¿Cuál es el formato oficial de los campos de fecha?
- ¿Los valores no reconocidos en el campo Tipo de CondicionesDePago son nuevas categorías o errores?
- ¿Los conteos esperados corresponden al total histórico o a un período específico?
- ¿Existe un diccionario de datos oficial con el significado de cada atributo y sus dominios válidos?

Conclusión general

La calidad de los datos es **parcialmente adecuada**. El proyecto es viable siempre que se incorpore una etapa de depuración previa al modelado dimensional y se documenten los supuestos, restricciones y decisiones de limpieza. Con ello, el almacén de datos y los tableros resultantes reflejarán información más confiable, consistente y útil para los análisis requeridos por RaSA.

Nota: las cifras por año y algunos conteos son sensibles al tratamiento de fechas y nulos; se reportan con el criterio metodológico indicado en cada sección y deben confirmarse tras la estandarización.