

Entendimiento de datos

Proyecto RaSA — Perfilamiento, análisis de calidad y conclusiones sobre los datos depurados

Base de datos fuente: **RaSaTransaccional** · Tecnología: PySpark sobre JupyterLab
Fuentes analizadas: Áreas de servicio, Tipos de beneficio, Planes-beneficio (tabla central) y Condiciones de pago (referencia).

Resumen ejecutivo

El trabajo comprendió tres etapas: un diagnóstico inicial de las fuentes (perfilamiento y análisis de calidad), la limpieza y depuración de los datos con base en ese diagnóstico, y las conclusiones sobre el conjunto ya depurado. El diagnóstico confirmó que las fuentes contienen la información necesaria para relacionar planes, beneficios, áreas de servicio y condiciones de pago, y también reveló problemas de completitud, unicidad, validez y consistencia. Tras aplicar las decisiones de depuración, los datos quedan en condiciones de integrarse mediante un esquema estrella y de soportar los tableros de control y análisis solicitados por RaSA.

Indicadores clave del diagnóstico inicial (datos sin depurar)

Fuente	Registros	Columnas	Duplicados completos	Hallazgo principal (previo a la limpieza)
Áreas de servicio	188.815	9	43.573 (23,1%)	Fechas y áreas fuera de rango; llave con nulos
Tipos de beneficio	849	9	271 (31,9%)	Banderas en varios idiomas; 178 ≠ 170 esperados
Planes-beneficio	36.036	11	8.493 (23,6%)	Llaves foráneas nulas y huérfanas; grano indefinido
Condiciones de pago	31	3	7 (22,6%)	Identificador repetido; 14 copagos (esperado 15)

1. Objetivo y alcance

El objetivo de la etapa de entendimiento de datos es explorar las fuentes provistas por RaSA, inspeccionar su nivel de calidad y evaluar la viabilidad de implementar los análisis solicitados. El trabajo se organiza en los siguientes momentos:

- **Perfilamiento (Entregable 1):** exploración de estructura, volumen y contenido de cada fuente, con registro de observaciones descriptivas.
- **Calidad de datos (Entregable 2):** evaluación de las cuatro dimensiones — completitud, unicidad, validez y consistencia — contra las reglas de negocio comunicadas por RaSA.
- **Limpieza y depuración:** aplicación de reglas de tratamiento sobre los problemas detectados.
- **Conclusiones (Entregable 3):** conclusiones sobre el conjunto ya depurado, las columnas de integración entre fuentes y las decisiones de limpieza documentadas.

Cada fila de las fuentes tiene un significado de negocio definido, resumido a continuación.

Fuente	Tabla en RaSaTransaccional	Significado de una fila
Áreas de servicio	FuenteAreasDeServicio_Copia_E	Un área de servicio definida sobre un condado, con población, área y densidad.
Tipos de beneficio	FuenteTiposBeneficio_Copia_E	Un tipo de beneficio y sus atributos (si es EHB, si tiene límite cuantitativo, exclusiones).
Planes-beneficio	FuentePlanesBeneficio_Copia_E	Un beneficio ofrecido por un plan en un área, con copago, coseguro y condiciones. Tabla central.
Condiciones de pago	FuenteCondicionesDePago_Copia_E	Una condición de pago de referencia (copago o coseguro).

RaSA comunicó además las siguientes cifras y reglas esperadas, usadas como referencia de contraste: 5.409 áreas de servicio que cubren todos los condados; 170 tipos de beneficio; 301 planes en 2017 y 422 en 2018; valores máximos de copago y coseguro para 2018 de 3.300 y 100; 15 condiciones de copago y 5 de coseguro; información de los años 2017 a 2019; y beneficios con límite cuantitativo que deben tener una cantidad límite distinta de cero.

2. Perfilamiento de datos

El perfilamiento se ejecutó cargando cada fuente vía Java Database Connectivity y aplicando funciones reutilizables de resumen (volumen y esquema), conteo de nulos, cardinalidad y frecuencias. Sus resultados son **exploratorios** y se confirman formalmente en el análisis de calidad.

2.1 Áreas de servicio

- 188.815 filas pero solo 5.409 valores distintos de `IdAreaDeServicio_T`: cada área se repite unas 35 veces, por lo que el identificador no es único por fila.
- La llave `IdAreaDeServicio_T` presenta 3,3% de nulos e `IdGeografia_T` 3,4%; `Area` y `Densidad`, 1,3%.
- Validez: `Area` con mínimo negativo (-24.707); `PoblacionAct` cercana a 47.000 millones; `Fecha` con años 2017, 2018 y un inválido 1800, sin 2019.
- Cobertura observada por debajo de lo esperado: alrededor de 35 estados y cerca de 4.250 condados.

2.2 Tipos de beneficio

- 849 filas con 178 valores distintos de `IdTipoBeneficio_T`: 8 más que los 170 esperados.
- `UnidadDelLimite` tiene 559 celdas vacías que el conteo de nulos no detecta y sí el análisis de completitud.
- Banderas booleanas con codificaciones e idiomas mezclados (por ejemplo No, Yes, Nein y Si).

2.3 Planes-beneficio (tabla central)

- 36.036 filas y 393 valores distintos de `IdPlan_T`; 8.493 duplicados completos.
- Llaves foráneas incompletas: `IdTipoBeneficio_T` 5,8% nulo e `IdAreaDeServicio_T` 5,7%. `cantidadLimite` 84,8% nula, coherente con que solo aplica a beneficios con límite.
- `valorCopago` alcanza 3.500 (200 por encima del tope de 3.300); `valorCoseguro` máximo 100, que coincide.

2.4 Condiciones de pago

- 31 filas, sin nulos, pero con identificador y descripción repetidos.
- El campo `Tipo` contiene valores no estandarizados además de copago y coseguro.

3. Análisis de calidad de datos

Sobre las mismas fuentes se evaluaron las cuatro dimensiones de calidad. El año se extrajo con un parser tolerante a varios formatos y la completitud consideró tanto valores nulos como cadenas vacías.

3.1 Completitud

CondicionesDePago no presenta faltantes. Los casos relevantes son:

Fuente	Campo	Faltantes	%	Lectura
Planes-beneficio	cantidadLimite	30.571	84,83	Esperable: solo aplica a beneficios con límite.
Tipos de beneficio	UnidadDelimite	559	65,84	Vacíos; interpretar junto a TieneLimiteCuantitativo.
Áreas de servicio	IdGeografia_T	6.378	3,38	Campo geográfico incompleto.
Áreas de servicio	IdAreaDeServicio_T	6.288	3,33	Crítico: es llave de integración con planes.
Planes-beneficio	IdTipoBeneficio_T	2.086	5,79	Llave foránea incompleta.
Planes-beneficio	IdAreaDeServicio_T	2.041	5,66	Llave foránea incompleta.

3.2 Unicidad

Ninguna llave simple identifica de forma única cada fila; todas presentan duplicados y repetición de identificadores.

Fuente	Total	Únicos	Duplic. completos	%	Distintos de la llave
Áreas de servicio	188.815	145.242	43.573	23,08	5.410 (IdAreaDeServicio_T)
Tipos de beneficio	849	578	271	31,92	178 (IdTipoBeneficio_T)
Planes-beneficio	36.036	27.543	8.493	23,57	393 (IdPlan_T)
Condiciones de pago	31	24	7	22,58	23 (IdCondicionesDePago_T)

La llave compuesta probada en PlanesBeneficio (plan, tipo, área, proveedor y fecha) deja 48,16% de duplicados y varios registros con IdTipoBeneficio_T nulo: el grano real requiere tratamiento previo.

3.3 Validez

Principales incumplimientos de formato, dominio o rango:

Fuente	Campo	Regla	Registros inválidos
Áreas de servicio	Fecha	Año entre 2017 y 2019	6.282
Áreas de servicio	Area	El área debe ser mayor que cero	6.177
Planes-beneficio	Fecha	Año entre 2017 y 2019	2.052
Tipos de beneficio	TieneLimiteCuantitativo	Valor booleano reconocible	24
Planes-beneficio	valorCopago	En 2018 no debe superar 3.300	8
Condiciones de pago	Tipo	Debe ser copago o coseguro	5
Tipos de beneficio	ExcluidoDelDesembolsoMaximoDentroDeLaRed	Valor booleano reconocible	2

3.4 Consistencia

Contraste con reglas de negocio e integridad referencial desde la tabla central:

Validación	Esperado	Encontrado	Estado
Beneficios con límite y cantidadLimite válida	0 inconsistentes	14.471	No cumple
Integridad: IdAreaDeServicio_T en planes	0 huérfanos	4.979	No cumple
Integridad: IdTipoBeneficio_T en planes	0 huérfanos	2.023	No cumple
Tipos de beneficio distintos	170	178	No cumple
Condiciones de copago	15	14	No cumple
Planes distintos 2017	301	203	No cumple
Planes distintos 2018	422	287	No cumple
Integridad: condición de copago / coseguro	0 huérfanos	0	Cumple

El hallazgo más crítico son los 14.471 registros de planes asociados a beneficios con límite cuantitativo cuya cantidadLimite es nula, cero o inválida. Los déficits de planes por año se explican en gran parte por fechas en formatos corruptos, llaves foráneas nulas y referencias huérfanas. Estos hallazgos definieron el alcance de la limpieza descrita en la siguiente sección.

4. Conclusiones sobre los datos depurados

Con base en el diagnóstico de las secciones 2 y 3 se aplicaron las actividades de limpieza y depuración sobre las cuatro fuentes. Las conclusiones de este apartado se refieren al **conjunto de datos ya depurado**, sobre el cual se evalúa qué análisis quedan habilitados para RaSA.

4.1 Decisiones de depuración aplicadas y su efecto

Acción de depuración	Efecto sobre los datos
Eliminación de duplicados completos	Cada registro representa un evento único; se removieron las repeticiones exactas de las cuatro fuentes.
Tratamiento de nulos en las llaves	Las llaves de integración quedan disponibles, habilitando el cruce entre PlanesBeneficio y las dimensiones.
Estandarización de fechas a un formato único	Los registros quedan en el rango 2017–2019 y los conteos por año son confiables y comparables.
Normalización de dominios y banderas	Los campos categóricos y booleanos usan un único formato homologado (por ejemplo Yes/No).
Depuración de catálogos de referencia	Tipos de beneficio y condiciones de pago quedan como catálogos sin repeticiones, aptos como dimensiones.
Resolución de referencias huérfanas	Las llaves foráneas de PlanesBeneficio se conciliaron con las dimensiones según la regla definida.

4.2 Modelo de integración resultante

Con los datos depurados, la integración se materializa en un **esquema tipo estrella**: PlanesBeneficio actúa como tabla de hechos, al nivel de un beneficio ofrecido por un plan en un área de servicio, y AreasDeServicio, TiposBeneficio y CondicionesDePago como dimensiones de referencia. Las columnas de integración, con los nombres reales de las tablas, son:

Desde (Planes)	Hacia (dimensión)	Columna destino	Estado
IdTipoBeneficio_T	TiposBeneficio	IdTipoBeneficio_T	Íntegra
IdAreaDeServicio_T	AreasDeServicio	IdAreaDeServicio_T	Íntegra
IdCondicionDePagoCopago_T	CondicionesDePago	IdCondicionesDePago_T (rol Copago)	Íntegra
IdCondicionDePagoCoseguro_T	CondicionesDePago	IdCondicionesDePago_T (rol Coseguro)	Íntegra

Sobre el conjunto depurado, los conteos por fuente pueden contrastarse de forma confiable con las cifras de referencia del negocio (5.409 áreas de servicio, 170 tipos de beneficio, 301 y 422 planes para 2017 y 2018, y 15 y 5 condiciones de copago y coseguro), lo que permite verificar la cobertura y detectar cualquier diferencia residual como decisión de negocio y no como problema de calidad.

4.3 Conclusiones para el negocio

- Los datos depurados permiten construir el **modelo dimensional** y los **tableros de control** solicitados, con PlanesBeneficio como tabla de hechos y las tres fuentes de referencia como dimensiones.
- Queda habilitado el análisis de **cobertura de beneficios** por área de servicio y región, apoyado en la dimensión geográfica (IdGeografia_T) de AreasDeServicio.
- Es posible analizar las **condiciones económicas** de los planes —copago y coseguro— por plan, tipo de beneficio y año, dentro de los rangos válidos del negocio.

- Se puede estudiar la **evolución temporal 2017–2019** y la comparación entre años, ahora que las fechas están estandarizadas.
- Se habilita la **clasificación de beneficios** por tipo, presencia de límite cuantitativo y exclusiones, útil para segmentar la oferta de planes.

4.4 Supuestos y decisiones documentadas

- IdAreaDeServicio_T, IdTipoBeneficio_T e IdCondicionesDePago_T identifican, respectivamente, un área, un tipo de beneficio y una condición de pago en sus tablas de dimensión.
- El grano de PlanesBeneficio se define como el beneficio ofrecido por un plan en un área de servicio en una fecha; IdPlan_T por sí solo no representa ese nivel de detalle.
- Los duplicados completos se trataron como problemas de calidad y se eliminaron.
- Los nulos en las llaves se trataron como información faltante, según la regla de depuración adoptada.
- Las diferencias residuales frente a las cifras de referencia se dejan documentadas para validación con RaSA.

Conclusión general

Tras la limpieza y depuración, la calidad de los datos es **adecuada** para avanzar hacia el modelado dimensional y la construcción de los tableros de control. El conjunto depurado integra las cuatro fuentes mediante un esquema estrella y soporta los análisis de cobertura, condiciones económicas, evolución temporal y clasificación de beneficios requeridos por RaSA, dejando documentados los supuestos y las decisiones de limpieza aplicadas.